# UNIVERSIDAD SANTO TOMÁS

## PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA

SECCIONAL TUNJA

VIGILADA MINEDUCACIÓN - SNIES 1732

Acreditación Institucional Internacional

OTORGADA POR EL IAC CINDA ACUERDO 55 DEL 8 DE MAYO–VIGENCIA 5 AÑOS

ACREDITACIÓN INSTITUCIONAL DE ALTA CALIDAD MULTICAMPUS

Vigencia por seis años

QS STARS RATED FOR EXCELLENCE

ISO 9001 icontec SC4289-1

CERTIFIED IQNet MANAGEMENT SYSTEM

UNIVERSIDAD SANTO TOMÁS
PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA
SECCIONAL TUNJA
VIGILADA MINEDUCACIÓN - SNIES 1732

**Faculty:** Systems engineer
**Course:** Deep Learning
**Topic:** **Sklearn – regresión logística**

---

**Professor:** Luis Fernando Castellanos Guarin
**Email:** Luis.castellanosg@usantoto.edu.co
**Phone:** 3214582098

# CONTENIDO

1. Perceptrón
2. Neuronas lineales adaptativas
3. Clasificadores de SCIKIT-LEARN
4. Predicción de flores usando un perceptrón.

¡Siempre hacia lo alto!

# Como funciona el cerebro biológico?

En 1943, Warren McCullock y Walter Pitts publicaron el primer concepto de una célula  cerebral.

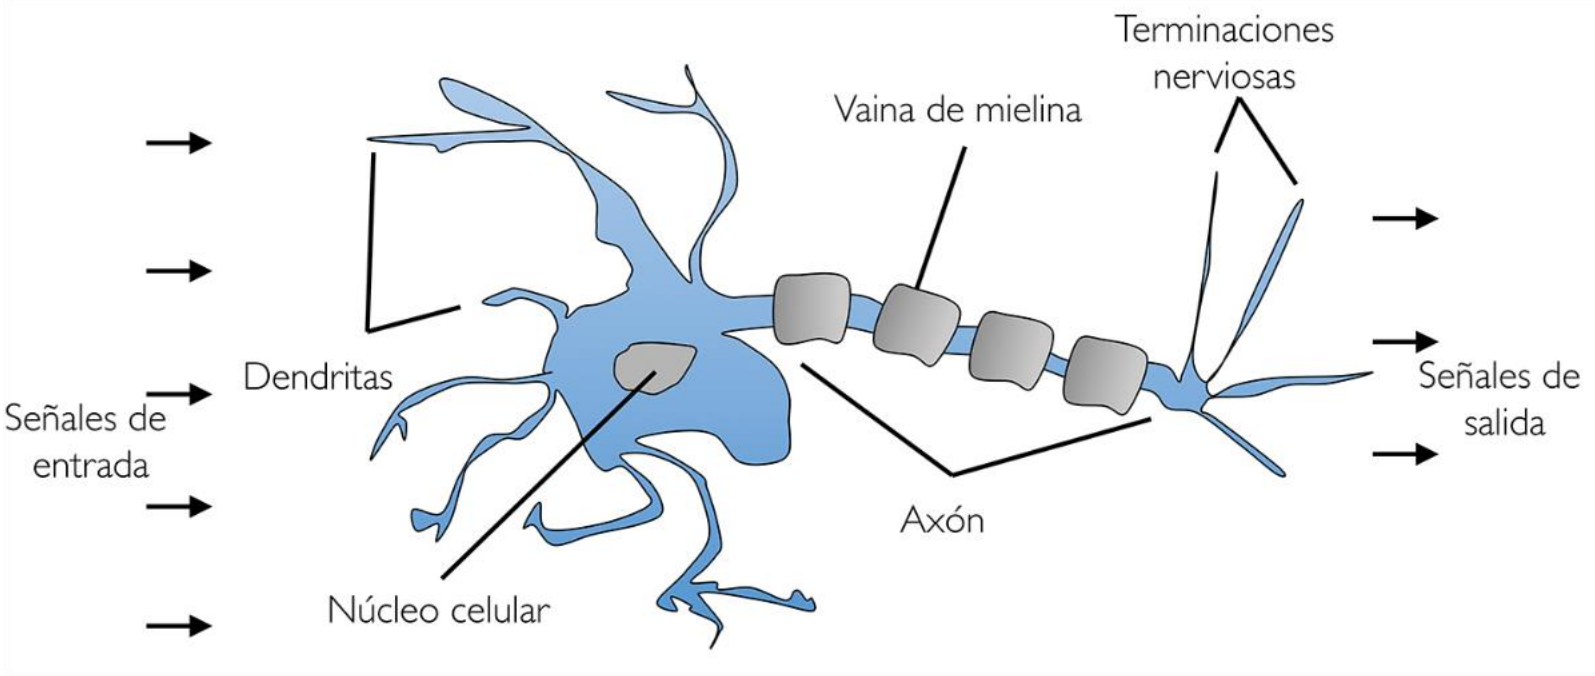


Las neuronas son células  nerviosas interconectadas en el cerebro que participan en el **proceso y la transmisión** de señales eléctricas y química.

¡Siempre hacia lo alto!

# Como funciona el cerebro biológico?

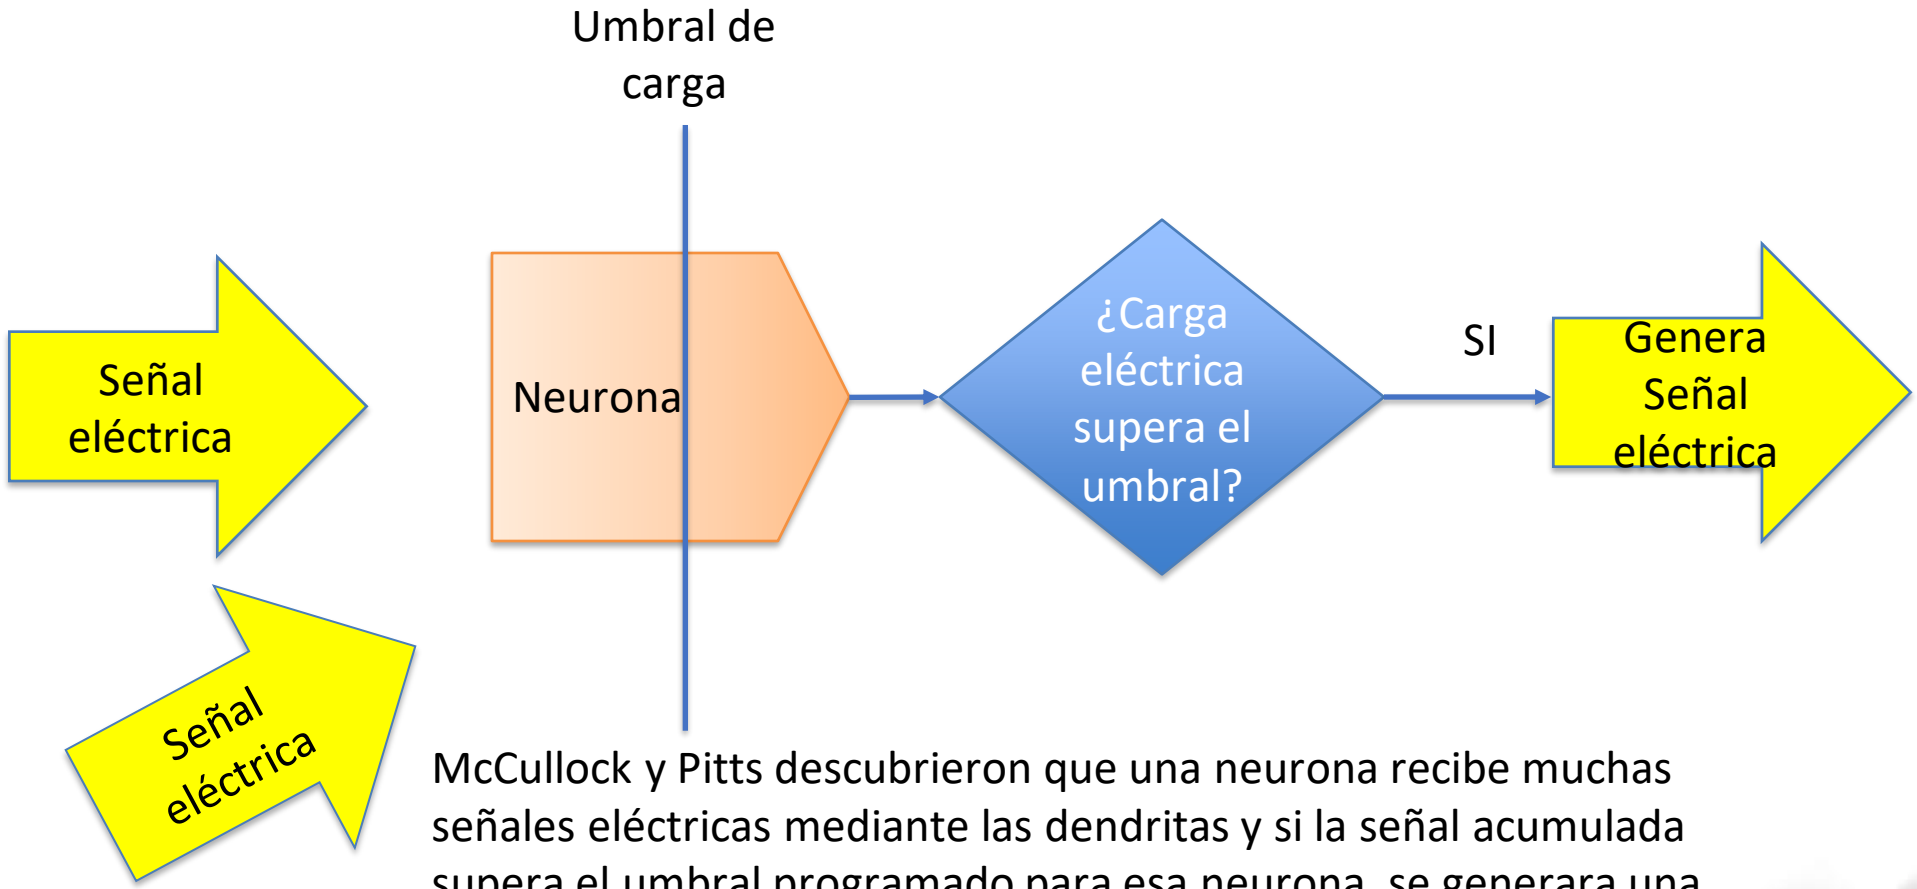


McCullock y Pitts descubrieron que una neurona recibe muchas señales eléctricas mediante las dendritas y si la señal acumulada supera el umbral programado para esa neurona, se generara una señal eletrica de salida.

# Perceptrón (un autómata de percepción y reconocimiento)

**Neurona Artificial (software)**

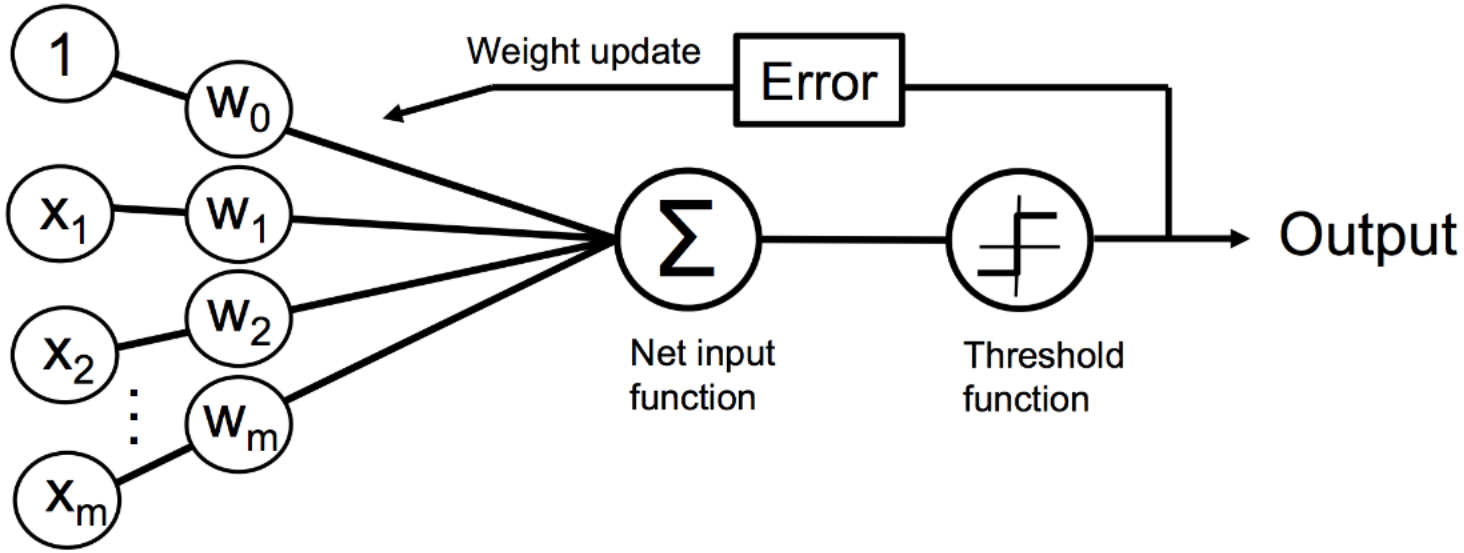


**Neurona biológica**

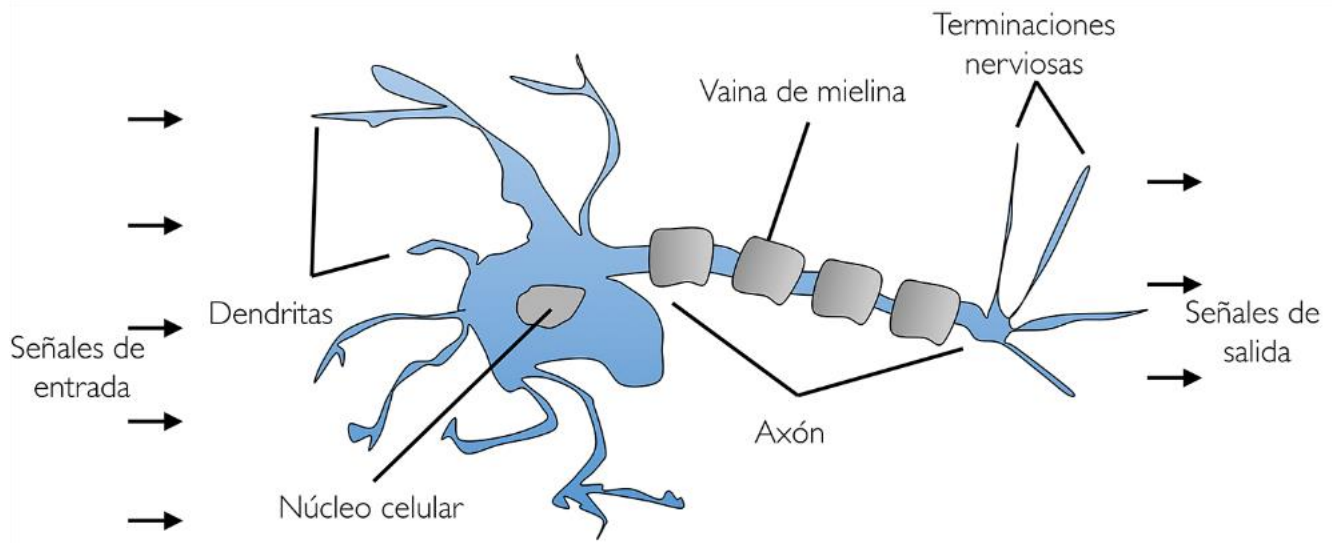


¡Siempre hacia lo alto!

# Perceptrón (un autómata de percepción y reconocimiento)

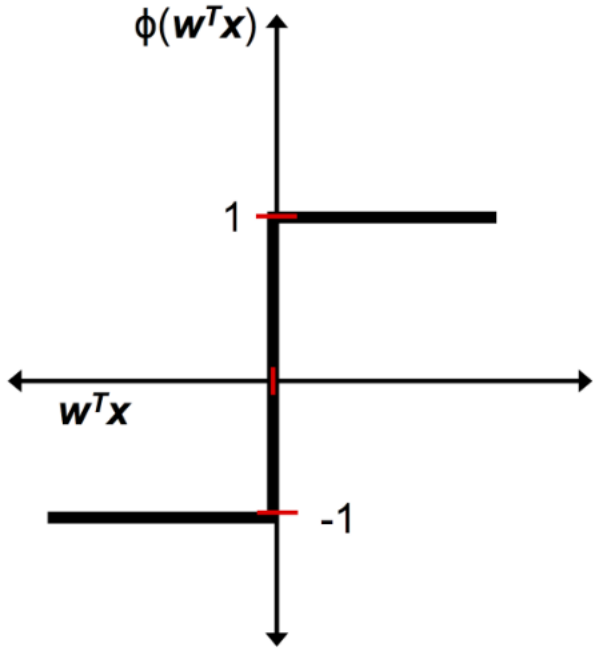


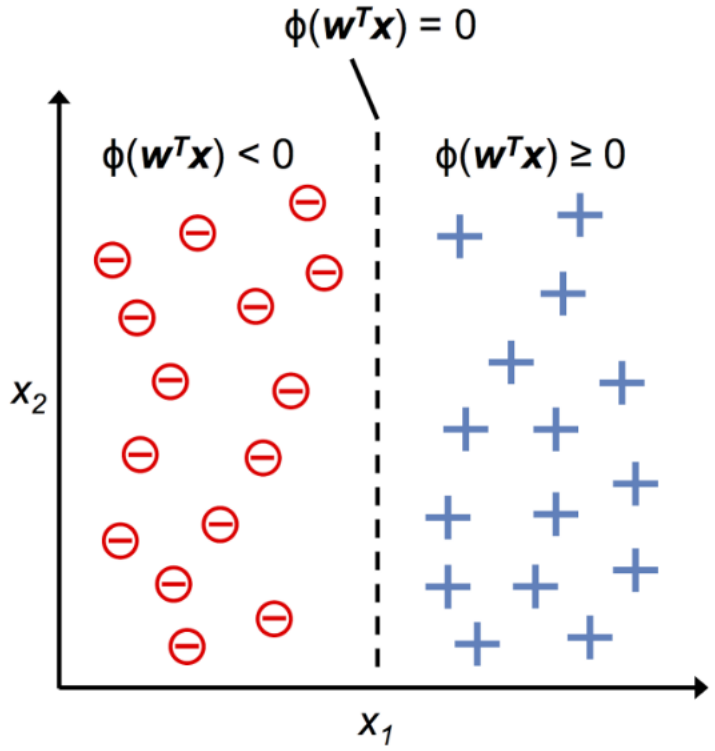


Un algoritmo que recibe una serie de valores negativos y positivos y si la sumatoria de sus valores pueden “excitar” o “no”(En caso que lo haga generara un valor a otro algoritmo).

# Perceptrón (un autómata de percepción y reconocimiento)

## código de un perceptrón en PYTHON

```
import numpy as np


class Perceptron(object):
    """Perceptron classifier.

    Parameters
    ------------
    eta : float
      Learning rate (between 0.0 and 1.0)
    n_iter : int
      Passes over the training dataset.
    random_state : int
      Random number generator seed for random weight
      initialization.

    Attributes
    -----------
    w_ : 1d-array
      Weights after fitting.
    errors_ : list
      Number of misclassifications (updates) in each epoch.

    """
    def __init__(self, eta=0.01, n_iter=50, random_state=1):
        self.eta = eta
        self.n_iter = n_iter
        self.random_state = random_state

    def fit(self, X, y):
        """Fit training data.

        Parameters
        ----------
        X : {array-like}, shape = [n_samples, n_features]
          Training vectors, where n_samples is the number of samples and
          n_features is the number of features.
        y : array-like, shape = [n_samples]
          Target values.

        Returns
        -------
        self : object
        rgen = np.random.RandomState(self.random_state)
        self.w_ = rgen.normal(loc=0.0, scale=0.01, size=1 + X.shape[1])
        self.errors_ = []

        for _ in range(self.n_iter):
            errors = 0
            for xi, target in zip(X, y):
                update = self.eta * (target - self.predict(xi))
                self.w_[1:] += update * xi
                self.w_[0] += update
                errors += int(update != 0.0)
            self.errors_.append(errors)
        return self

    def net_input(self, X):
        """Calculate net input"""
        return np.dot(X, self.w_[1:]) + self.w_[0]

    def predict(self, X):
        """Return class label after unit step"""
        return np.where(self.net_input(X) >= 0.0, 1, -1)
```

# Neuronas lineales adaptativas - ADALINE

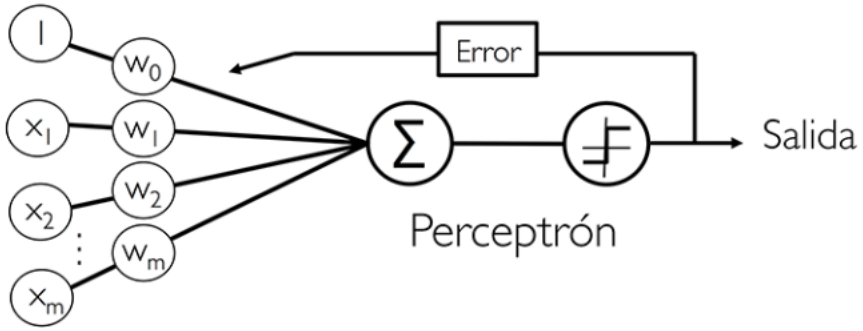


*Compara las etiquetas de clase verdaderas con las etiquetas de clase predichas.*

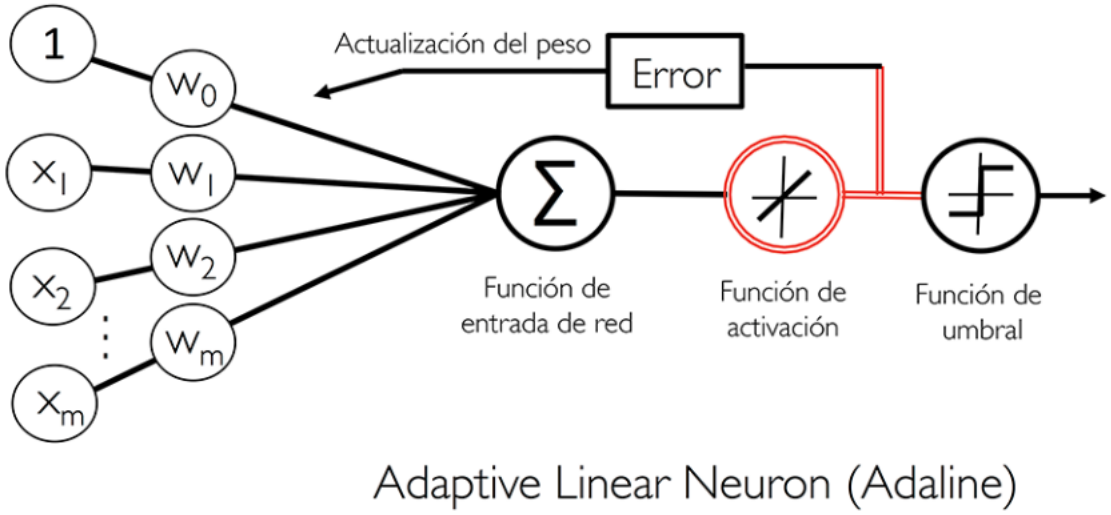


*Compara las etiquetas de clase verdaderas con salida de valores continuos de la función de activación lineal para calcular el error del modelo y actualizar pesos*

ADALINE, Surge como una mejora al perceptrón pues permite definir y minimizar las funciones de coste continuas. Esto sienta las bases para la compresión de algoritmos de aprendizaje automático como la **regresión logística, maquina de vectores de soporte y modelos de regresión.**

¡Siempre hacia lo alto!

# Clasificadores (algoritmos) de aprendizaje automático con SCIKIT-LEARN

## Clasificadores de SCIKIT-LEARN

- Los  Algoritmos más populares para clasificación, como regresión logística, maquinas de vectores de soporte y arboles de decisión.

- Ejemplos de SCIKIT-LEARN

- Fortalezas y debilidades de los clasificadores.

## Clasificadores de SCIKIT-LEARN

En machine learning un algoritmo de clasificación solo es apropiado ***para una tarea*** problemática...difícilmente para dos o más.

# Clasificadores de SCIKIT-LEARN

**Viejos métodos y poco prácticos.**

Perceptrón
ADALINE

**Nuevos métodos y muy prácticos.**

SCIKIT-LEARN

# Resumen (paso a paso para hacer una IA)

1. Conocer el dataset
2. Dividir los datos (entrenamiento / testeo)
3. Escalado y normalización de valores
4. Entrenar modelo.
5. Realizar predicciones
6. Valorar el modelo.
7. *Visualizar resultados (opcional)*

## Que otros modelo existen?

**TALLER PARA CASA: ver videos sobre:**

1. Regresión lineal (simple/múltiple)
2. Regresión logística y probabilidades condicionales.
3. Vectores de soporte.
4. Árboles de clasificación y regresión
5. K-vecinos (k-means).

***Para conocer de forma genérica la funcionalidad de esos modelos***

# ¿Pero qué tipos de modelos de IA Existen?

- *Regresión lineal (Es método para encontrar el patrón con una "Mejor Línea de Ajuste")*
- *Regresión logística.*
- *Árboles de clasificación y regresión.*
- Vectores de soporte
- *K-means*
- *Redes bayesianas*
- ***Deep learning***

# Regresión logística

***Regresión logística:*** Es una técnica de aprendizaje supervisado para clasificación. Es muy usada en muchas industrias debido a su escalabilidad y explicabilidad.

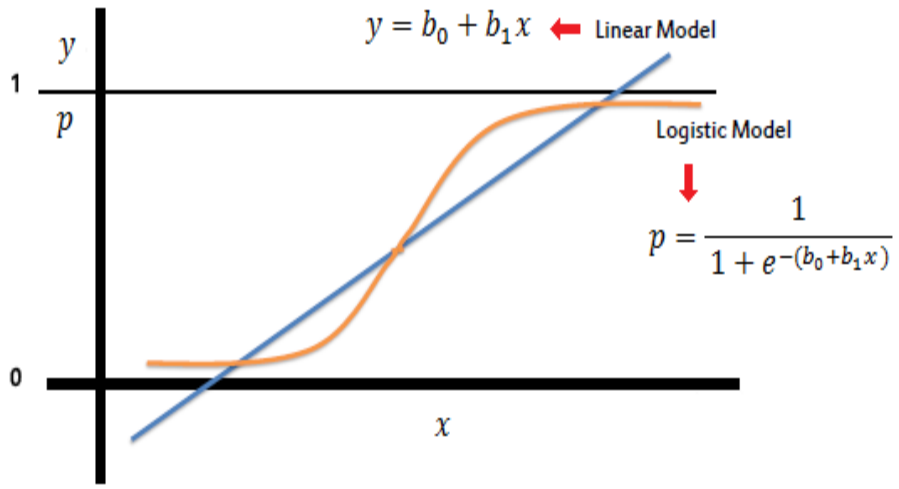


Podemos diferenciar tres tipos de regresiones logísticas:

- **Regresión Logística Binaria:** es la Regresión Logística clásica, en la que hay dos clases a predecir.
- **Regresión Logística Multinomial:** hay más de dos categorías a predecir, pero las clases no guardan ningún orden entre ellas (determinar el texto de un artículo del periódico es de: Entretenimiento, Deportes, Política)
- **Regresión Logística Ordinal:** hay más de dos categorías a predecir y existe un orden entre las categorías (por ejemplo predecir en que posición va a quedar cada equipo al final de la liga de futbol)

# Regresión logística

Iniciaremos con la **Regresión Logística Binaria:**

La usaremos para clasificar situaciones con dos posibles estados binarios (1 ó 0)_ “SI/NO” o en un número finito de “etiquetas” o “clases” múltiple.

Algunos Ejemplos de Regresión Logística son:

- Clasificar si el email que llega es Spam o No
- un tumor clasificado como “Benigno” o “Maligno”.

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

Conociendo el dataset (datos):

El profesor “**Freddy Michael Kruege Myres”**, no tiene claro que tiempo recomendarle a los estudiantes para que estudien para el examen y con ello garantizar las mejores notas de los estudiantes.

Por lo tanto recolecta la base de datos de los últimos 2000 exámenes donde están las horas que estudiaron y si aprobó o reprobó.

La base de datos esta disponible en:

https://github.com/luisFernandoCastellanosG/Machine_learning/tree/master/Databaset_para_trabajar_sklearn

Denominada: **horas_estudio_vs_aprobacion.csv**

**Pasos:**

1. Importar la librerías
2. Cargar el **dataset** al entorno de trabajo usando **Google drive**
3. Conociendo los datos
4. Prepara los datos de entrenamiento
5. Importa el módulo **LogisticRegression** de la librería **scikit-learn**
6. **Entrenar** la regresión logística con los datos de entrenamiento
7. Usar el modelo entrenado para obtener las **predicciones** con datos nuevos
8. Obtener las **probabilidades** de la predicción

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

**Pasos:**

1. Importar la librerías

```
import numpy as np              #Mejora el soporte para vectores y matrices
import pandas as pd             #Estructura de datos (Ciencia de datos)

import matplotlib.pyplot as plt #Para graficar
import seaborn as sns           #interfaz de alto nivel para dibujar gráficos estadísticos (basada en matplotlib)
```

2. Cargar el **dataset** al entorno de trabajo usando **Google drive**

```
from google.colab import drive
drive.mount('/content/gdrive')
```

2.1. Cargar el dataset en un dataframe de pandas

```
df = pd.DataFrame()
df = pd.read_csv('…/horas_estudio_vs_aprobacion.csv', encoding='utf-8')
```

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

3. Conociendo los datos

```
#primeros 5 regirstros del dataframe
df.head()
#dimensiones del dataframe
df.shape
```

3.1 visualizando la distribución de los datos.

```
sns.set(rc={'figure.figsize':(11.7,8.27)})  #tamaño del grafico
sns.distplot(df['horas'])                   #agregamos los datos
plt.show()
```

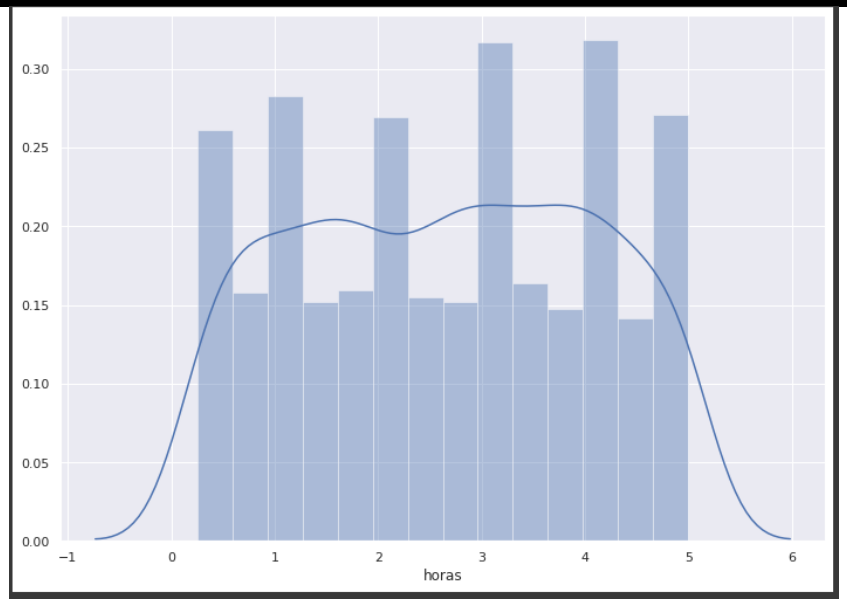

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

4.Separando los datos para el entrenamiento

```
#En X colocaremos el tiempo de estudio que tomaron los estudiantes antes del examen
#apilamos los datos que vienen en 1d a 2d
#opcion 1: usamos np.c_
X = pd.DataFrame(np.c_[df['horas']], columns = ['horas'])
#opcion2: usamos .reshape(-1, 1)
X = np.array(df['horas']).reshape(-1, 1)
#En Y colocaremos el resultado del examen (1 / 0 ) (aprobado / reprobado)
y= np.array(df['aprueba'])
print(X)
```

5. importamos la clase LogisticRegresion de scikit-learn.

```
#clase de regresión logistica disponsible en sklearn
from sklearn.linear_model import LogisticRegression
#Creamos una instancia de la Regresión Logística
regresion_logistica = LogisticRegression()
```

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

6. Entrena la regresión logística con los datos de entrenamiento

```
#entrenando
regresion_logistica.fit(X,y)
```

7. Haciendo predicciones.
Tomaremos una grupo de horas y miraremos que probabilidad de pasar el examen tenemos

```
#definimos que pasa si el estudiante estudia entre 1 a 6 horas
X_nuevo = np.array([1, 2, 3, 4, 5, 6]).reshape(-1,1)
#ejecutamos la predicción
prediccion = regresion_logistica.predict(X_nuevo)
print(prediccion)
```

## ¿Que predicción que nos dio es buena?

# Regresión logística – ejercicio 1: aprobar examen vs horas de estudio

8. Generando probabilidades de la predicción

```
probabilidades_prediccion = regresion_logistica.predict_proba(X_nuevo)
#la primera columna es la probabilidad de reprobar
#la segunda columna es  la probabilidad de aprobar
print(probabilidades_prediccion)
#si solo nos interesa la probabilidad de aprobar
print(probabilidades_prediccion[:,1])
```

## ¿Es buena la inferencia de aprobación?

# Regresión logística – ejercicio 2: aprobar examen (estudio y tutorías)

Con los mismos pasos pero ahora con una variable nueva:

Horas de estudio + **Horas de tutoría** vs (aprobó / reprobó)

Pasos:

1.Cargando Librerías necesarias

```
import pandas as pd
import numpy as np

import seaborn as sns
import matplotlib.pyplot as plt
from sklearn import metrics
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
```

2. Cargar el dataset en un dataframe de pandas

```
df = pd.DataFrame()
df = pd.read_csv('...../horas_estudio_tutorias_vs_aprobacion.csv', encoding='utf-8')
```

# Regresión logística – ejercicio 2: aprobar examen (estudio y tutorías)

3. Conociendo los datos

```
#primeros 5 registros del dataframe
df.head()
```

3.1 visualizando el tamaño de los datos.

```
#dimensiones del dataframe
print("matrix df [MxN] ->"+str(df.shape))
#verificamos que no hayan nulos
print("---Columnas con valores nulos--")
print(df.isnull().sum())
```

3.2 visualizando la distribución de los datos.

```
sns.set(rc={'figure.figsize':(11.7,8.27)})  #tamaño del grafico
sns.distplot(df['tutorias_mes'])                #agregamos los datos
plt.show()
```

# Regresión logística – ejercicio 2: aprobar examen (estudio y tutorías)

4. Separando los datos para el entrenamiento

*Separaremos las características y etiquetamos como **X** e **Y** respectivamente.*

- *la variable X (horas_autoestudio_diario + tutorias_mes)*
- *la varible Y (aprobo_perdio)*

```
x = df.drop('aprobo_perdio',axis = 1)
y = df.aprobo_perdio
```

Dividiremos los datos en conjuntos de train y test. Esto separará 25%(! valor predeterminado) de los datos en un subconjunto para la parte de prueba y el 75% restante se usará para nuestro subconjunto de entrenamiento.

```
#separamos los datos 25%(test) y 75%(train)
x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=4)
#Si deseamos cambiar la proporción solo debemos agregar la variable test_size=0.x
x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=4,test_size=0.2)
```

**¿De que depende la proporción de datos para entrenamiento?**
**¿Que hace que se escoja un 25% o un 20% o un 30%?**

# Regresión logística – ejercicio 2: aprobar examen (estudio y tutorías)

5. importamos la clase LogisticRegresion de scikit-learn.

```
#Creamos una instancia de la Regresión Logística
regresion_logistica = LogisticRegression()
```

6. Entrena la regresión logística con los datos de entrenamiento

```
#entrenando modelo de regresión logistica
regresion_logistica.fit(x,y)
```

7.Haciendo predicciones

```
#usaremos el 25% de los datos para probar el modelo
#ejecutamos la predicción con datos de prueba (x_test)
y_prediccion = regresion_logistica.predict(x_test)
```

# Regresión logística – ejercicio 2: aprobar examen (estudio y tutorías)

8. Generando probabilidades de la predicción

```
#comparamos los datos de predicción (y_prediccion) VS los datos de prueba (y_test)
exactitud = metrics.accuracy_score(y_test, y_prediccion)
print("exactitud_percentaje= "+str(100 * exactitud))
```

probemos con datos manuales para probar el modelo

```
#hagamos prediccion con datos manuales:
#              [horas_estudio , horas_tutoria]
#1-estudiante: [ 4             , 38 ]
#2-estudiante: [ 8             , 29 ]
#3-estudiante: [ 1             , 1  ]
alumnos=np.array([[4, 38], [8, 29],[1,1],[0,0]])
x_nuevo = pd.DataFrame(alumnos,columns = ['horas_autoestudio_diario','tutorias_mes'])
y_prediccion = regresion_logistica.predict(x_nuevo)
print(y_prediccion)
```

# ¿Tiene lógica la predicción del modelo?

# Tarea de regresión lineal  y logísticas:

En la carpeta de github:

https://github.com/luisFernandoCastellanosG/Machine_learning/tree/master/Dataset_para_trabajar_sklearn

Descargar el dataset denominado: **mercadeo_bancario.csv**

El conjunto de datos proviene del repositorio UCI Machine Learning, (***con unos cambios que se le realizaron***) y está relacionado con campañas de marketing directo (llamadas telefónicas) de una institución bancaria portuguesa.

El objetivo de clasificación es **predecir si el cliente se suscribirá (1/0)** a un depósito a plazo (variable y)

# Tarea de regresión lineal y logísticas:

**Variables del dataset**

- **edad** (numérica)
- **trabajo**: tipo de trabajo (categórico: "admin", "housemaid", "management", "retired", "self-employed", "student", "technician", "unemployed", "unknown")
- **conyugal**: estado civil (categórico: "divorciado", "casado", "único", "desconocido")
- **educación** (categórica: "preschool", "primary_school", "tecnical_school", " Technological_school", "illiterate", "professional.course", "university.degree", "unknown")
- **Total_hijos**: número total de hijos
- **credito_sin_pago**: ¿tiene crédito en incumplimiento de pago? (categóricamente: "no", "sí", "desconocido")
- **prestamo_vivienda**: ¿tiene préstamo de vivienda? (categóricamente: "no", "sí", "desconocido")
- **prestamo_personal**: ¿tiene préstamo personal? (categóricamente: "no", "sí", "desconocido")
- **valor_préstamo**:(numérico) es el valor total del prestamos que tiene con el banco
- **tarjetas_credito:** Número de tarjetas de crédito con otros bancos
- **contacto**: tipo de comunicación de contacto (categórico: "celular", "teléfono")
- **mes**: último mes de contacto del año (categórico: "jan", "feb", "mar", ..., "nov", "dec")
- **dia_semana**: último día de contacto de la semana (categórico: "mon", "tue", "wed", "thu", "fri")
- **duracion_ultimo_contacto**: duración del último contacto, en segundos (numérico). Nota importante: este atributo afecta en gran medida al destino de salida (p. ej., si duration-0 y 'no').
- **campanna**: número de contactos realizados durante esta campaña y para este cliente (numérico, incluye el último contacto)
- **dias_ultimo_contacto**: número de días que pasaron después de que el cliente fue contactado por última vez desde una campaña anterior
- **anterior_contacto**: número de contactos realizados antes de esta campaña y para este cliente (numérico)
- **resultado_anterior**: resultado de la campaña de marketing anterior (categórica: "fracaso", "inexistente", "éxito")
- **numero_empleados**: número de empleados que tiene a su cargo — (numérico)
- **Predecir variable (objetivo deseado):** (binario: "1", significa "Sí", "0" significa "No")

# Tarea de regresión lineal y logísticas:

**En grupos de tres personas (A,B,C,D) "*deben darle un nombre al grupo*", van a crear dos modelos de machine learning:**

- 1° modelo, generado con el algoritmo de regresión lineal, donde deben identificar cuales son las variables con mejor correlación y hacer predicción
- 2° modelo, generado con el algoritmo de Regresión Logística Binaria y hacer predicción.

Responder las siguientes preguntas (usando código en Python):

- La edad promedio de los clientes que dijeron que SI y los que dijeron que NO (si_no)
- Cual fue el porcentaje que tomaron para separar el dataset en (train y test) y por que?
- Cual esa la precisión de cada modelo (lineal y logística)?
- En la regresión lineal cuales fueron las variables con mejor correlación y cuales no?

**Nota**: para realizar predicciones con modelos de machine learning **NUNCA** se debe trabajar con datos en formato **texto**, por lo tanto si los campos están en texto es necesario convertirlos a números, ejemplo el campo "**estado_civil**"

| Valores categóricos | Valores en números |
|---|---|
| married | 1 |
| single | 2 |
| divorced | 3 |
| unknown | 0 |

# Tarea de regresión lineal  y logísticas:

**Asignación de variables:**

**Grupo A:**

- Edad
- Estado_civil
- Total_hijos
- Contacto
- mes
- Si_no

**Grupo B:**

- edad
- Trabajo
- Credito_sin_pago
- Valor_préstamo
- dia_semana
- Si_no

**Grupo C:**

- Edad
- prestamo_vivienda
- dias_utimo_pago
- anterior_contacto
- duracion_ultimo_contacto
- Si_no

**Grupo D:**

- Edad
- Educacion
- prestamo_personal
- tarjetas_crédito
- numero_empleados
- Si_no