



# UNIVERSIDAD SANTO TOMÁS

PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA

SECCIONAL TUNJA

VIGILADA MINEDUCACIÓN - SNIES 1732



Acreditación Institucional  
**Internacional**

OTORGADA POR EL IAC CINDE ACUERDO 55 DEL 6 DE MAYO-VIGENCIA 5 AÑOS



Vigencia por seis años







UNIVERSIDAD SANTO TOMÁS  
PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA  
SECCIONAL TUNJA

VIGILADA MINEDUCACIÓN - SNIES 1732

**Faculty:** Systems engineer  
**Course:** Deep Learning  
**Topic:** sentiment analysis

---

**Professor:** Luis Fernando Castellanos Guarín  
**Email:** [Luis.castellanosg@usantoto.edu.co](mailto:Luis.castellanosg@usantoto.edu.co)  
**Phone:** 3214582098



# CONTENIDO

Código en Python para cada una de las fases de preparación del corpus:


- Obtención de los tres corpus.
- Convertir archivos XML del CORPUS a CSV

¡Siempre  
hacia lo alto!





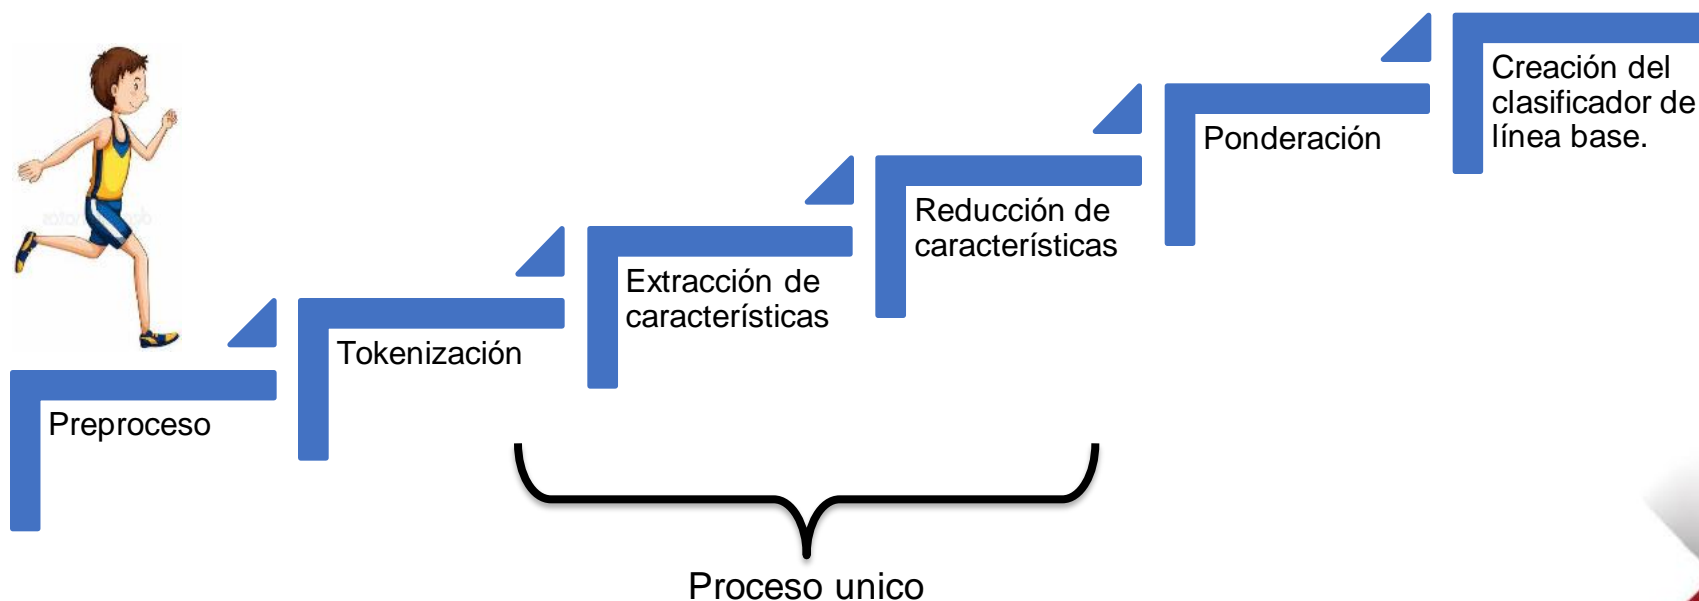
En esta semana exploraremos el **análisis de los datos de redes sociales** a los que se accede desde **Twitter** mediante Python. Utilizaremos la API **RESTful de Twitter** para acceder a los datos sobre los usuarios de Twitter y sobre qué se tuitea.







# Fases de preparación del corpus



¡Siempre  
hacia lo alto!



## 0. Obtener corpus

Seguiremos con el mismo libro de jupyter (**ANALISIS\_SENTIMIENTOS.ipynb**).

Con los archivos que descargaremos del link que nos enviaron al correo crearemos una carpeta en Google drive:

```
▼ [icon] Analisis_sentimientos_Twitter
  ▼ [icon] datasets
    [icon] tass
```

Dentro de tass dejaremos los archivos XML



## 0. Obtener corpus

Desde el **Taller de Análisis de Sentimientos (TASS)** que pertenece a la Sociedad Española para el Procesamiento del Lenguaje Natural (SEPLN) existen publicadas tres corpus que son los de más uso para nuestro idioma “El español” para analizar tweets (cada tweet está debidamente etiquetado con el sentimiento...similar al de películas):

- **General Corpus**, que incluye 68000 tweets escritos en español por 150 personajes y celebridades conocidas dentro del mundo de la política, economía, comunicación y cultura y que fueron obtenidos entre noviembre de 2011 y marzo de 2012.
- **Politics Corpus (STOMPOL)**, que ofrece 2500 tweets extraídos durante la campaña de Elecciones a las Cortes Generales de España de 2011. Estos mensajes mencionan a los cuatro partidos políticos más relevantes de aquel momento: PP, PSOE, IU y UPyD.
- **International TASS Corpus (InterTASS)**: contiene 3400 mensajes de Twitter escritos en español y sobre cualquier tipo de tema.

<http://www.sepln.org/workshops/tass/>

Luego ingresamos en la sección de DATASETS (el año más reciente) y vamos a la sección de download, registramos los datos necesarios en el formulario y esperamos que nos envíen un email con la URL de descarga.

Cree una carpeta en drive

By signing this License, the End User engages to strictly respect the conditions set forth herein and to respect all the data and personality protection with regard to the data contained within the Dataset collected and processed by the

Full name:

Organization:

Country:

Contact Email:

(make sure that the email is correct because you will receive the information to download the Dataset in your inbox)



# 0. Obtener corpus

Generar CSV desde XML

**Cargue de librerías necesarias.**

```
import xml.etree.ElementTree as etree
import csv
from os import scandir
from sklearn.model_selection import train_test_split
```

**Función para convertir listas en archivos CSV**

```
def list_to_csv(data, filename):
    with open(filename, 'w', encoding='utf-8') as csvfile:
        writer = csv.writer(csvfile, delimiter=',', lineterminator='\n', quoting=csv.QUOTE_NONNUMERIC)
        writer.writerows(data)
```

**función para cargar de un CSV a una LISTA (messages | labels)**

```
def csv_to_lists(filename):
    messages = []
    labels = []
    with open(filename, 'r', encoding='utf-8') as csvfile:
        reader = csv.reader(csvfile, delimiter=',')
        for row in reader:
            messages.append(row[1])
            labels.append(row[2])
    return messages, labels
```





# 0. Obtener corpus

Generar CSV desde XML

Funciones para prasear xml en un lista según cada corpus

- corpus de general tweetid | content | sentiments/polarity/value

```
def general_tass_to_list(filename):  
    tree = etree.parse(filename)  
    root = tree.getroot()  
    data = []  
  
    for tweet in root:  
        tweetId = tweet.find('tweetid').text  
        content = tweet.find('content').text  
        polarityValue = tweet.find('sentiments/polarity/value').text  
        data.append([tweetId, content.replace('\n', ' '), polarityValue])  
    return data
```

¡Siempre  
hacia lo alto!



# 0. Obtener corpus

Generar CSV desde XML

Funciones para prasear xml en un lista según cada corpus

- **Corpus politics tweetid | content | sentiments/polarity**

```
def politics_tass_to_list(filename):  
    tree = etree.parse(filename)  
    root = tree.getroot()  
    data = []  
  
    for tweet in root:  
        tweetId = tweet.find('tweetid').text  
        content = tweet.find('content').text  
        aux = next((e for e in tweet.findall('sentiments/polarity') if e.find('entity') == None), None)  
        if aux != None:  
            polarityValue = aux.find('value').text  
            data.append([tweetId, content.replace('\n', ' '), polarityValue])  
    return data
```

¡Siempre  
hacia lo alto!



# 0. Obtener corpus

Generar CSV desde XML

Funciones para prasear xml en un lista según cada corpus

- Corpus internacional tweetid | content | sentiments/polarity

```
def intertass_tass_to_list(filename, qrel=None):
    tree = etree.parse(filename)
    root = tree.getroot()
    data = []

    for tweet in root:
        tweetId = tweet.find('tweetid').text
        content = tweet.find('content').text
        polarityValue = tweet.find('sentiment/polarity/value').text
        if polarityValue == None:
            polarityValue = qrel[tweetId]
        data.append([tweetId, content.replace('\n', ' '), polarityValue])
    return data
```

Función para separar el 100% del corpus entre: Train : 70% - Test: 30%

```
def generate_train_test_subsets(data, size):
    codes = [d[0] for d in data]
    labels = [d[2] for d in data]
    codes_train, codes_test, labels_train, labels_test = train_test_split(codes, labels, train_size=size)
    train_data = [d for d in data if d[0] in codes_train]
    test_data = [d for d in data if d[0] in codes_test]
    return train_data, test_data
```





# 0. Obtener corpus

Generar CSV desde XML

## Ejecutar funciones

```
#tomamos el corpus internacional (test) y generamos una lista del ID del tweet y el sentimiento para agregarlo a la data
qrel = gold_standard_to_dict("../Analisis_sentimientos_Twitter/datasets/tass/intertass-sentiment.qrel")
data = []
data.extend(general_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/general-test-tagged-3l.xml"))
data.extend(general_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/general-train-tagged-3l.xml"))
data.extend(intertass_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/intertass-development-tagged.xml"))
#como el test del corpus internacional esta sin los sentimientos es necesario agregarlos : qrel
data.extend(intertass_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/intertass-test.xml", qrel))
data.extend(intertass_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/intertass-train-tagged.xml"))
data.extend(politics_tass_to_list("../Analisis_sentimientos_Twitter/datasets/tass/politics-test-tagged.xml"))

train, test = generate_train_test_subsets(data, size=0.7)

list_to_csv(data, '../Analisis_sentimientos_Twitter/datasets/global_dataset.csv')
```

¡Siempre  
hacia lo alto!



## 0. Obtener corpus

Generar CSV desde XML

### Taller

Crear un archivo denominado **DatasetHelper.py**, donde se defina una clase **class DatasetHelper:** Y dentro de ella se consoliden todas las funciones descritas en las diapositivas anteriores.

### Nota:

Todos los métodos deben tener la definición **@staticmethod**

Donde se determinan que son estáticos lo que permite que en la mayoría de las funcionalidades son mejores como funciones de nivel de módulo en Python por razones de limpieza. Con una función de módulo es más fácil importar solo la función que necesita y evitar "" innecesarios, ejemplo:

```
@staticmethod
```

```
def general_tass_to_list(filename):
```



# 1. Preprocesamiento

## Descargar librerías necesarias

```
#Descargamos la libreria de stopwords  
import nltk  
nltk.download('stopwords')
```

## Cargamos el CSV del corpus de google drive

```
from google.colab import drive  
drive.mount('/content/drive')
```

¡Siempre  
hacia lo alto!





# 1. Preprocesamiento

## Cargar librerías necesarias y variable necesarias

```
import re #librería para la búsqueda y manipulación de cadenas
from nltk import TweetTokenizer #librería para tokenizar
from nltk.stem import SnowballStemmer #algoritmo para clasificación de palabras

#variables para mejorar la escritura (opcional)
NORMALIZE = 'normalize'
REMOVE = 'remove'
MENTION = 'twmention'
HASHTAG = 'twhashtag'
URL = 'twurl'
LAUGH = 'twlaugh'
#definir que el algoritmo de clasificación use el idioma español
_stemmer = SnowballStemmer('spanish')

#definir una variable para la funcion de tokenizar (opcional)
_tokenizer = TweetTokenizer().tokenize
```

## Definir listas de conversión

```
#lista de conversión para quitar las tildes a las vocales.
DIACRITICAL_VOWELS = [('á', 'a'), ('é', 'e'), ('í', 'i'), ('ó', 'o'), ('ú', 'u'), ('ü', 'u')]

#lista para corregir algunas palabras coloquiales / jerga en español (obviamente faltan más)
SLANG = [('d', 'de'), ('[qk]', 'que'), ('xo', 'pero'), ('xa', 'para'), ('[xp]q', 'porque'), ('es[qk]', 'es que'),
          ('fvr', 'favor'), ('(xfa|xf|pf|plis|pls|porfa)', 'por favor'), ('dnd', 'donde'), ('tb', 'también'),
          ('(tq|tk)', 'te quiero'), ('(tqm|tkm)', 'te quiero mucho'), ('x', 'por'), ('\+', 'mas')]
```



# 1. Preprocesamiento

## Funciones necesarias

Creación de funciones que serán necesarias para el preprocesamiento de los mensajes

- Método para normalización de risas

```
#método para normalizar las risas
def normalizeLaughs(message):
    message = re.sub(r'\b(?\w*[j])[aeiouj]{4,}\b', LAUGH, message, flags=re.IGNORECASE)
    message = re.sub(r'\b(?\w*[k])[aeiouk]{4,}\b', LAUGH, message, flags=re.IGNORECASE)
    message = re.sub(r'\b(juas+|lol)\b', LAUGH, message, flags=re.IGNORECASE)
    return message
```

Ejemplo:

```
print (normalizeLaughs("esto muyy feliz jajajajaja o no tan feliz jejejejeje o mejor me rio a como pa  
pa noel JOJOJO o como en mileniams LOL"))
```

```
esto muyy feliz twlaugh o no tan feliz twlaugh o mejor me rio a como papa  
noel twlaugh o como en mileniams twlaugh
```

¡Siempre  
hacia lo alto!



# 1. Preprocesamiento

## Funciones necesarias

Creación de funciones que serán necesarias para el preprocesamiento de los mensajes

- **Método para eliminar o normalizar menciones, hashtags y URLs**

```
def process_twitter_features(message, twitter_features):

    message = re.sub(r'[\.\,]http', '. http', message, flags=re.IGNORECASE)
    message = re.sub(r'[\.\,]#', '. #', message)
    message = re.sub(r'[\.\,]@', '. @', message)

    if twitter_features == REMOVE:
        # eliminar menciones, hashtags y URL
        message = re.sub(r'((?<=\s)|(?<=\A))(@|#)\S+', '', message)
        message = re.sub(r'\b(https?:\S+)\b', '', message, flags=re.IGNORECASE)
    elif twitter_features == NORMALIZE:
        # cuando sea necesario se normalizaran las menciones, hashtags y URL
        message = re.sub(r'((?<=\s)|(?<=\A))@\S+', MENTION, message)
        message = re.sub(r'((?<=\s)|(?<=\A))#\S+', HASHTAG, message)
        message = re.sub(r'\b(https?:\S+)\b', URL, message, flags=re.IGNORECASE)

    return message
```

### Ejemplo:

```
print(process_twitter_features("Rosell, una noche. Adivina quien!! http://t.co/PPAwijRX", "remove"))
```

Rosell, una noche. Adivina quien!!

¡Siempre  
hacia lo alto!





# 1. Preprocesamiento

Funciones necesarias

Creación de funciones que serán necesarias para el preprocesamiento de los mensajes

- **Método global**

```
def preprocess(message):  
    # convertir a minusculas  
    message = message.lower()  
  
    # eliminar números, retorno de linea y el tan odios retweet (de los viejos estilos de twitter)  
    message = re.sub(r'(\d+|\n|\brt\b)', '', message)  
  
    # eliminar vocales con signos diacríticos (posible ambigüedad)  
    for s,t in DIACRITICAL_VOWELS:  
        message = re.sub(r'{0}'.format(s), t, message)  
  
    # eliminar caracteres repetidos  
    message = re.sub(r'(\.|\d)\1{2,}', r'\1\1', message)  
  
    # normalizar las risas  
    message = normalizeLaughs(message)  
  
    # traducir la jerga y terminos coloquiales sobre todo en el español  
    for s,t in SLANG:  
        message = re.sub(r'\b{0}\b'.format(s), t, message)  
  
    #normalizar/eliminar hashtags, menciones y URL  
    message = process_twitter_features(message, _twitter_features)  
  
    #Convertir las palabras a su raiz ( Bonita, bonito) -> bonit  
    if _stemming:  
        message = ' '.join(_stemmer.stem(w) for w in _tokenizer(message))  
  
    return message
```



# 1. Preprocesamiento

Funciones necesarias

Taller:

Usando las funciones:

- Para cargar de un CSV a una LISTA, `def csv_to_lists(filename)`
- Preprocesamiento de textos, `def preprocess(message)`

Crear el Código en python para cargar el archivo **CSV** “*datasets/train\_dataset\_30.csv*” y realizar el preprocesamiento a cada uno de los tweets y salvar nuevamente el dataset en un nuevo csv denominado **train\_dataset\_30\_clean.csv**

¡Siempre  
hacia lo alto!



# 1. Preprocesamiento

Funciones necesarias

## Aplicamos preprocesamiento al CSV y creamos un nuevo CSV limpio

```
import numpy as np
import pandas as pd

df = pd.read_csv('/content/drive/My Drive/IA/Análisis_sentimientos_Twitter/datasets/dataset_2017_full.csv', encoding='utf-8')
#asignamos nombres a las columnas del csv para facilitar la búsqueda de información
df.columns = ['tweetid', 'tweet', 'sentiment']
#aplicamos el preprocesamiento a los tweets con steaming =false
df['tweet'] = df['tweet'].apply(preprocess)
#eliminamos la columna tweetid que no nos sirve para entrenar y si nos genera mas uso de memoria
df = df.drop(columns="tweetid")
#Es mejor trabajar con valores enteros que con letras
#por lo tanto reemplazaremos los sentimientos que estan como NONE->-1 | NEU -> 0 | P->1 | N->2
df.loc[df['sentiment'] == 'NONE', 'sentiment'] = '-1'
df.loc[df['sentiment'] == 'NEU', 'sentiment'] = '0'
df.loc[df['sentiment'] == 'P', 'sentiment'] = '1'
df.loc[df['sentiment'] == 'N', 'sentiment'] = '2'
df["sentiment"].unique()
#guardamos el dataset en un nuevo CSV para facilitar su posterior uso
df.to_csv('/content/drive/My Drive/IA/Análisis_sentimientos_Twitter/datasets/dataset_2017_full_clean.csv', index=False, encoding='utf-8')
```

¡Siempre  
hacia lo alto!





## 5.2. tokenización

### Función de tokenizar

Esta función permite convertir cada uno de los tweets en un vector donde cada uno de los elementos es una palabra o símbolo gramatical.

```
def tokenizer(text):  
    text = re.sub('<[>]*>', '', text)  
    emoticons = re.findall('(?:::|;|=)(?:-)?(?:\)|\(|D|P)', text.lower())  
    text = re.sub('[\W]+', ' ', text.lower()) + ' '.join(emoticons).replace('-', '')  
    tokenized = [w for w in text.split() if w not in stop]  
    return tokenized
```



## 5.3. Extracción de características

```
#p2.2: función para extraer un documento del dataset
print("p2.2: funcion para extraer un documento del dataset ")
def stream_docs(path):
    with open(path, 'r', encoding='utf-8') as csv:
        next(csv) # skip header
        for line in csv:
            text, label = line[:-3], int(line[-2])
            yield text, label
#p2.3: función que tomara una secuencia de documentos y devolverá un número particular de documentos
def get_minibatch(doc_stream, size):
    docs, y = [], []
    try:
        for _ in range(size):
            text, label = next(doc_stream)
            docs.append(text)
            y.append(label)
    except StopIteration:
        return None, None
    return docs, y
```



## 5.4. Entrenamos el modelo

usaremos regresión logística porque es menos costoso en tiempo de procesamiento que “support vector machine”

```
path='/content/drive/My Drive/IA/Análisis_sentimientos_Twitter/datasets/dataset_2017_full_clean.csv'
#p2: definimos una versión liviana de CountVectorizer+TfidfVectorizer llamada HashingVectorizer
from sklearn.feature_extraction.text import HashingVectorizer
from sklearn.linear_model import SGDClassifier

vect = HashingVectorizer(decode_error='ignore',
                        n_features=2**21,
                        preprocessor=None,
                        tokenizer=tokenizer)

#definimos como algoritmo la regresión logística en el descenso gradiente

clf = SGDClassifier(loss='log', random_state=1, max_iter=1)
doc_stream = stream_docs(path)
#p3. entrenamos
import re
import numpy as np
import pyprind
from nltk.corpus import stopwords
stop = stopwords.words('spanish')
pbar = pyprind.ProgBar(50)
#definimos las clases con las cuales vamos a entrenar
classes = np.array([-1,0, 1,2])
#hacemos 50 repeticiones
for _ in range(50):
    #tomaremos grupos de 500 tweets para entrenar
    X_train, y_train = get_minibatch(doc_stream, size=500)
    if not X_train:
        break
    X_train = vect.transform(X_train)
    clf.partial_fit(X_train, y_train, classes=classes)
    pbar.update()
#probamos la eficiencia del modelo con 500 tweets .
X_test, y_test = get_minibatch(doc_stream, size=500)
X_test = vect.transform(X_test)
print('Presición del modelo: %.3f' % clf.score(X_test, y_test))
#recalibramos el modelo.
clf = clf.partial_fit(X_test, y_test)
```

**...Creamos una IA que clasifique (positivo, negativo, neutro)  
un texto  
con una acertabilidad del 80%...  
con eso creamos SKYNET...QUE SUSTOOOOOOOOOO**



**¡Siempre  
hacia lo alto!**





## Serializamos (congelamos) el modelo

Serializamos (congelamos) el modelo para usarlo fuera de google colab, de esta forma crearemos dos archivos portables que se podrían usar en Android/iOS/Windows/Linux o en una página web.

```
import pickle
import os
#creo una carpeta en mi google drive para guardar los archivos serializados
dest = os.path.join('/content/drive/My Drive/IA/Análisis_sentimientos_Twitter/twitterclassifier',
'pkl_objects')
if not os.path.exists(dest):
    os.makedirs(dest)
#convertimos el clasificador y el stopword en archivo/objetos pkl
pickle.dump(stop, open(os.path.join(dest, 'stopwords.pkl'), 'wb'), protocol=4)
pickle.dump(clf, open(os.path.join(dest, 'classifier.pkl'), 'wb'), protocol=4)
#Es importante recordar que deben verificar que los dos archivos esten en su drive
```

¡Siempre  
hacia lo alto!



## Serializamos (congelamos) el modelo

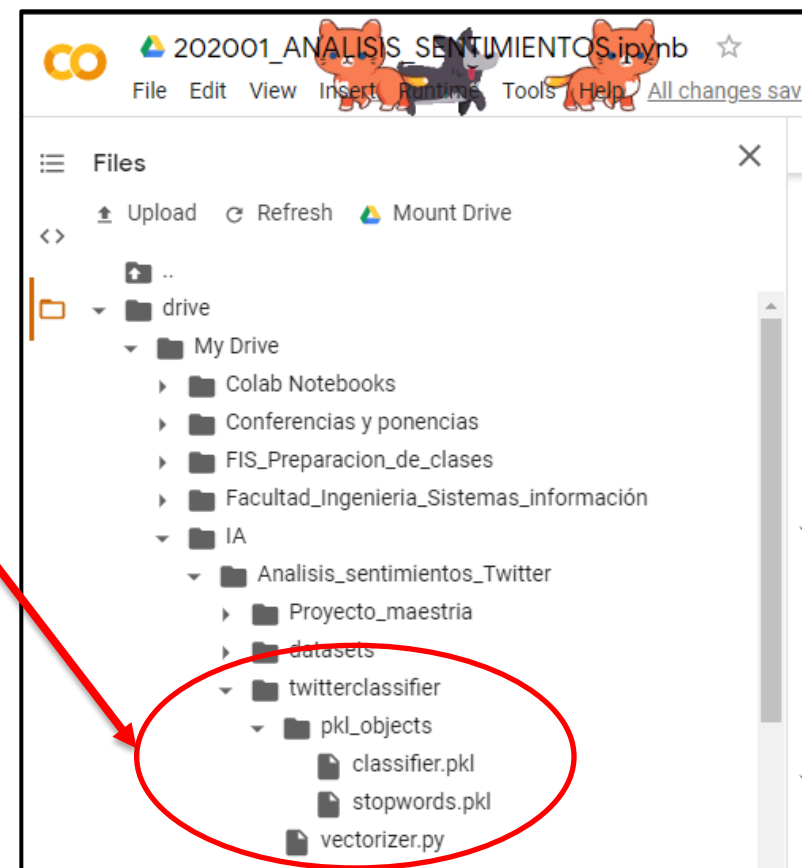
guardamos en drive en la carpeta de **twitterclassifier** un archivo de Python llamado **vectorizer.py** para usar el **HashingVectorizer** más tarde (me permitirá convertir cualquier texto en un vector).

```
from sklearn.feature_extraction.text import HashingVectorizer
import re
import os
import pickle
```

```
cur_dir = os.path.dirname(__file__)
stop = pickle.load(open(
    os.path.join(cur_dir,
        'pkl_objects',
        'stopwords.pkl'), 'rb'))
```

```
def tokenizer(text):
    text = re.sub('<[^\>]*>', '', text)
    emoticons = re.findall('(?:[:;|=](?:-)?(?:\)|\(|D|P)',
        text.lower())
    text = re.sub('[\W]+', ' ', text.lower()) \
        + ''.join(emoticons).replace('-', '')
    tokenized = [w for w in text.split() if w not in stop]
    return tokenized
```

```
vect = HashingVectorizer(decode_error='ignore',
    n_features=2**21,
    preprocessor=None,
    tokenizer=tokenizer)
```





## Problemas a ver si funciona

Cambiamos la basepath (directorio por defecto) de Python a la carpeta de **Twitterclassifier**

```
import os
os.chdir('/content/drive/My Drive/IA/Analisis_sentimientos_Twitter/twitterclassifier')
```

Deserializamos los estimadores

```
import pickle
import re
import os
from vectorizer import vect
clf = pickle.load(open(os.path.join('pkl_objects', 'classifier.pkl'), 'rb'))
```



# Probemos a ver si funciona

Clasifiquemos un texto

```
import numpy as np
#NONE->-1 | NEU -> 0 | P->1 | N->2
label = {-1:'Sin sentimiento', 0:'Neutro', 1:'Positivo', 2: 'Negativo'}

#example = ['Te odio más que a la muerte']
example1 = 'covid19 te ODI0000'
example = [example1]
#convertimos el texto en un vector de palabras y extraemos sus características https://scikit-learn.org/stable/modules/feature\_extraction.html
textConvert = vect.transform(example)
print('*Predicción: %s\n*Probabilidad: %.2f%%'%(label[clf.predict(textConvert)[0]], np.max(clf.predict_proba(textConvert))*100))
print('*Predicción: %s'%label[clf.predict(textConvert)[0]])
print(np.max(clf.predict_proba(textConvert))*100)
```

¡Siempre  
hacia lo alto!





# RECORREMOS LOS TWEETS DESCARGADOS Y LOS CLASIFICAMOS

**Cargaremos los tweets de COVID19 (aproximadamente 1000)**

```
import numpy as np
import pandas as pd
import pyprind


df = pd.read_csv('/content/drive/My Drive/IA/Analisis_sentimientos_Twitter/datasets/TWEETS_LGGG_COVID19.csv', encoding='utf-8')
#creamos una columna llamada Sentimient donde guardaremos la predicción
df['sentiment'] = ''
#creamos una columna llamada Probability donde guardaremos la acertabilidad que dio el clasificador
df['probability']=0
#conversión de sentimientos (numeros a palabras)= NONE->-1 | NEU -> 0 | P->1 | N->2
label = {-1:'Sin sentimiento', 0:'Neutro', 1:'Positivo',2: 'Negativo'}
for rowid in range(len(df.index)):
    text=df['text'][rowid]
    textConvert = vect.transform([text])
    df['sentiment'][rowid]=label[clf.predict(textConvert)[0]]
    df['probability'][rowid]=np.max(clf.predict_proba(textConvert))*100
    pbar.update()
df.head(20)
#df.to_csv('/content/drive/My Drive/IA/Analisis_sentimientos_Twitter/datasets/TWEETS_LGGG_COVID19_analysis.csv', index=False, encoding='utf-8')
```



## Generemos gráficos estadísticos

Generemos algunos gráficos estadísticos que nos ayuden a verificar que tan eficiente fue el modelo

```
import matplotlib.pyplot as plt
#sentimientos = df["sentiment"].unique()
df.groupby('sentiment')['location'].nunique().plot(kind='bar')
print(df.groupby(['sentiment']).size())
#df.groupby(['sentiment']).size().unstack().plot(kind='bar',stacked=True)
plt.show()
```



¡Siempre  
hacia lo alto!



## Taller investigativo

**Taller:** Crear un repositorio en **Github** denominado **DeepLearning** y en el una carpeta denominada **Analisis\_sentimientos\_Twitter**.

Dentro de esta carpeta debe estar:

- Carpeta del clasificador



- Libro de jupyter (código fuente)
- Csv con los tweets para hacerles análisis y de resultado (sentimiento).
- **Pdf** con los printscreen de los gráficos estadísticos.



## Taller investigativo

Taller: Desde el CRAI-de la USTA TUNJA (<https://ustatunja.edu.co/inicio-biblioteca>)

Investigar que cuanto material académico:

- Libros
- Capítulos de libro
- Artículos
- Ponencias

Se tienen sobre análisis de sentimientos usados en Twitter.

Adicional a esto tome un **artículo**, el de su preferencia y realice el siguiente análisis:

- Cual fue el corpus que usaron (de donde obtuvieron la base o si ellos la crearon).
- Que técnica de aprendizaje utilizaron para entrenar el modelo.
- Que acertabilidad (probabilidad de acertar) obtuvieron (¿si fue superior al 80%?).
- A que conclusiones llegaron los investigadores.
- Responda si con lo que ha aprendido en clase de Deep learning usted recomendaría ese proyecto?